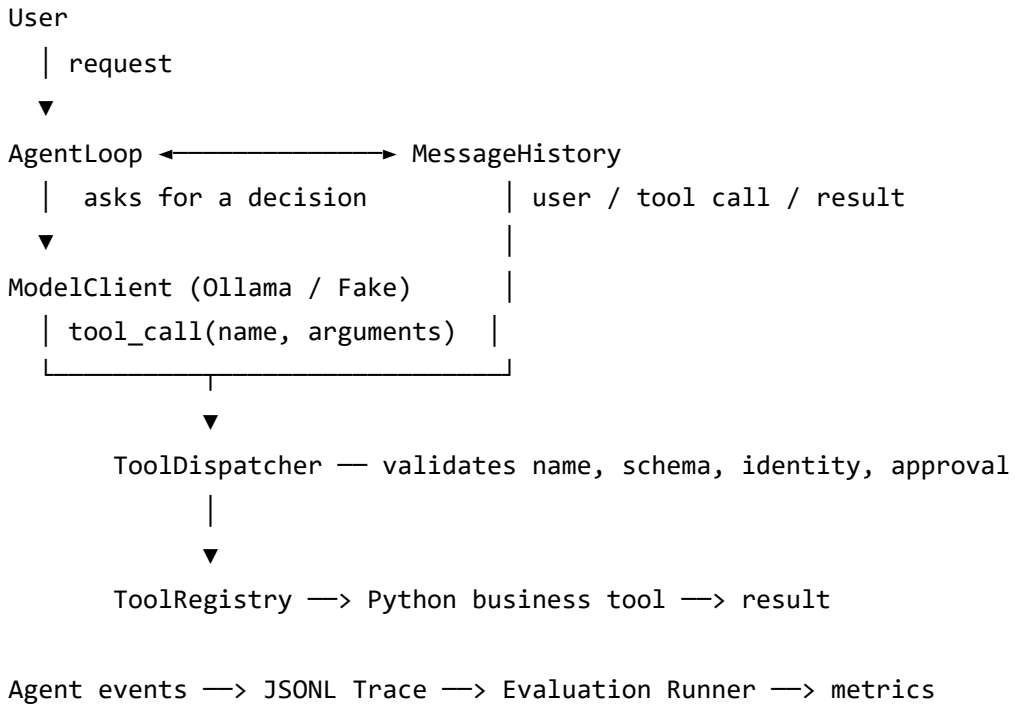
Mini AI Agent — Interview Cheat Sheet

一句话记住

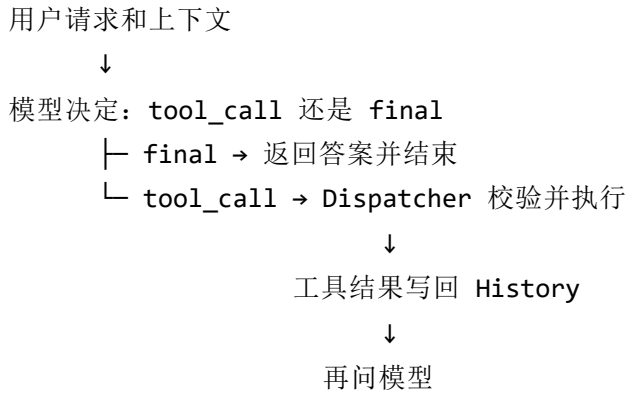
LLM 提议下一步，Agent Runtime 检查并执行；工具结果回到上下文，循环直到回答或触发限制。

架构图



模型输出的是结构化决策，不会直接运行 Python。Dispatcher 才是实际调用工具的运行时代码。

Agent Loop



Agent 必须有停止条件，例如 final answer、最大决策步数或超时。工具调用本身不代表成功；要检查工具结果。

十个核心术语

Term	面试时怎么解释
Agent Loop	反复进行模型决策、工具调用、观察结果，直到结束的循环。
Tool Calling	模型用结构化格式提出工具名和参数。
Dispatcher	应用中负责校验并实际执行工具调用的组件。
Tool Registry	运行时允许调用的工具清单。
Structured Output	要求模型按固定 JSON 结构返回决策。
Schema Validation	检查字段、类型和必填参数是否符合约定。
Authentication	确认当前用户是谁。
Authorization	判断当前用户能否执行某个操作。
Human-in-the-loop	重要操作暂停，等待人审核后再执行。
Trace / Evaluation	Trace 记录一次运行；Evaluation 用预期结果检查一组场景。

常见概念区别

Agent vs Workflow：Workflow 按预先确定的步骤走；Agent 可以根据模型决策动态选择下一步。实际系统常用 Workflow 固定边界，把少数判断步骤交给 Agent。

Function Calling vs MCP：Function Calling 是模型提出函数调用的方式；MCP 是应用之间提供和调用工具、资源的协议。它们不是同一个东西，可以组合使用。本项目使用 Function Calling 风格的 JSON 决策和本地 Python 工具，没有实现 MCP。

Memory vs State vs Trace：Memory 给模型提供可参考的上下文；State 表示业务当前事实；Trace 记录运行中发生的事件。日志里记录了状态，不等于系统能从日志恢复状态。

Single Agent vs Multi-Agent：单 Agent 更容易控制、测试和排错。只有任务确实能拆成相对独立的专业工作时，再考虑 Multi-Agent；多个 Agent 会增加通信、状态协调和评估成本。

Offline Evaluation：离线跑固定场景并与预期结果比较，适合发布前回归。人工 Review 和 LLM-as-Judge 可辅助评价开放式回答；Judge 应用人工结果校准。权限和越权执行仍要用确定性检查。本项目只有小型固定场景，没有人工 Review 或 LLM Judge。

五道系统设计追问

1. How would you design a safe support Agent?
先从应用取得用户身份，再把有限的工具交给模型。Dispatcher 校验工具名和参数，并用运行时身份做授权。只读查询按权限执行；创建工单暂停等人批准。添加超时、步数限制、Trace 和回归评估。

2. How do you handle prompt injection?
不把 System Prompt 当权限边界。工具层独立校验身份、数据范围和参数；只执行注册工具。用攻击输入验证，即使模型提出危险调用，也不能读到无权访问的数据。

3. How do you prevent duplicate side effects?
为副作用请求设计幂等键，并在服务端持久化处理状态。重试同一个键时返回原结果，不重复创建。当前 Playground 只阻止同一审批 ID 被重复处理，没有实现持久化幂等。

4. What if the model or a tool is slow or unavailable?
对模型和工具分别设超时，并限制 Agent 步数。明确记录失败状态。读取操作可按策略重试；副作用不能未经幂等保护就盲目重试。

5. How do you know a new model version is better?
用固定的正常、边界、越权和故障场景比较版本，检查实际工具结果而不只看模型自述。结合成功率、工具选择、安全指标、人工抽查和生产监控。

90 秒英文介绍

> I built a small customer-support Agent to understand how tool calling works at runtime. A user request goes to an Agent loop, which asks a local Ollama model for a structured decision. The model can propose a balance lookup, an order lookup, or a support-ticket request, but it does not execute code. A dispatcher validates the tool and its arguments, passes a runtime user identity (fixed in this demo), and calls only registered tools. Ticket creation pauses for human approval. I added JSONL traces and a small evaluation runner as well. In my deterministic local suite, six scenarios passed, including an invalid tool call and a cross-user access attempt. In a separate run, phi4-mini passed five local scenarios and refused the cross-user request. These are results from a simulated learning project, not production results or a description of an employer's internal system.

面试前自测

1. 谁真正执行工具：LLM 还是 Dispatcher?
2. 为什么 JSON Schema 合法不代表用户有权限?
3. Trace 与 Evaluation 分别回答什么问题?
4. 如果工单处于 `PENDING_APPROVAL` ，它是否已经创建?
5. 当前实验验证了什么，又没有验证什么?